

COURS. STATISTIQUE DESCRIPTIVE

Chapitre 04. Série Statistique Double

Département Mathématiques.

PRESENTATION
Dr. André Souleye Diabang

29 novembre 2021

Plan

- 1 Introduction
- 2 Représentation graphique. Nuage de points
- 3 Paramètres d'une série statistique double.
- 4 Les droites de regression.

Plan

- 1 Introduction
- 2 Représentation graphique. Nuage de points
- 3 Paramètres d'une série statistique double.
- 4 Les droites de regression.

Introduction

Les statistiques à une variable s'intéressaient, pour une population donnée, à un caractère donné : les notes à un devoir surveillé d'une classe, les salaires dans une entreprise, etc. . .

Introduction

Les statistiques à une variable s'intéressaient, pour une population donnée, à un caractère donné : les notes à un devoir surveillé d'une classe, les salaires dans une entreprise, etc. . .
Lorsque l'on s'intéresse à l'étude simultanée de deux caractères d'une même population, on fait ce que l'on appelle des statistiques à deux variables, en étudiant des séries statistiques doubles.

Introduction

On considère une population d'effectif n , si on étudie deux caractères X et Y de cette population,

Introduction

On considère une population d'effectif n , si on étudie deux caractères X et Y de cette population, on dit que l'on étudie une série statistique double.

Introduction

On considère une population d'effectif n , si on étudie deux caractères X et Y de cette population, on dit que l'on étudie une série statistique double.

Chaque individu de cette population est désigné par un nombre compris entre 1 et n .

Introduction

On considère une population d'effectif n , si on étudie deux caractères X et Y de cette population, on dit que l'on étudie une série statistique double.

Chaque individu de cette population est désigné par un nombre compris entre 1 et n . A chaque individu i ($1 \leq i \leq n$) correspond un couple $(x_i; y_i)$, ou x_i est la modalité du caractère X et y_i est la modalité du caractère Y associé à l'individu i .

Introduction

On considère une population d'effectif n , si on étudie deux caractères X et Y de cette population, on dit que l'on étudie une série statistique double.

Chaque individu de cette population est désigné par un nombre compris entre 1 et n . A chaque individu i ($1 \leq i \leq n$) correspond un couple $(x_i; y_i)$, ou x_i est la modalité du caractère X et y_i est la modalité du caractère Y associé à l'individu i . L'ensemble des couples $(x_i; y_i)$ définit une série statistique à deux variables.

Introduction

On considère une population d'effectif n , si on étudie deux caractères X et Y de cette population, on dit que l'on étudie une série statistique double.

Chaque individu de cette population est désigné par un nombre compris entre 1 et n . A chaque individu i ($1 \leq i \leq n$) correspond un couple $(x_i; y_i)$, où x_i est la modalité du caractère X et y_i est la modalité du caractère Y associé à l'individu i . L'ensemble des couples $(x_i; y_i)$ définit une série statistique à deux variables.

Lorsque l'un des deux caractères est une année, une date, on dit que la série statistique double est une série chronologique.

Application. B1

Exemple

Le tableau ci-dessous permet de suivre l'évolution de l'espérance de vie à la naissance (en années) d'un pays de 2012 à 2021 pour les femmes :

Année	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021
rang (xi)	0	1	2	3	4	5	6	7	8	9
Espérance de vie (yi)	80,9	81,1	81,3	81,4	81,8	81,9	82,0	82,3	82,4	82,4

Plan

- 1 Introduction
- 2 Représentation graphique. Nuage de points
- 3 Paramètres d'une série statistique double.
- 4 Les droites de regression.

Nuage de points.

Définition.

Si l'on appelle x_1, x_2, \dots, x_n les n valeurs du premier caractère (on notera cette série (x_i)),

Nuage de points.

Définition.

Si l'on appelle x_1, x_2, \dots, x_n les n valeurs du premier caractère (on notera cette série (x_i)), et si l'on appelle y_1, y_2, \dots, y_n les n valeurs du second caractère (on notera cette série (y_i)),

Nuage de points.

Définition.

Si l'on appelle x_1, x_2, \dots, x_n les n valeurs du premier caractère (on notera cette série (x_i)), et si l'on appelle y_1, y_2, \dots, y_n les n valeurs du second caractère (on notera cette série (y_i)), alors on représente cette série statistique double par un nuage de points dans un repère du plan, constitué des points M_i de coordonnées (x_i, y_i)

Nuage de points.

Définition.

Si l'on appelle x_1, x_2, \dots, x_n les n valeurs du premier caractère (on notera cette série (x_i)), et si l'on appelle y_1, y_2, \dots, y_n les n valeurs du second caractère (on notera cette série (y_i)), alors on représente cette série statistique double par un nuage de points dans un repère du plan, constitué des points M_i de coordonnées (x_i, y_i)

Exemple.

Représenter le nuage de points de la série B1.

Plan

- 1 Introduction
- 2 Représentation graphique. Nuage de points
- 3 Paramètres d'une série statistique double.
- 4 Les droites de regression.

Le point moyen.

Définition.

Soit \bar{x} la moyenne de la série (x_i) et \bar{y} la moyenne de la série (y_i) .

Le point moyen.

Définition.

Soit \bar{x} la moyenne de la série (x_i) et \bar{y} la moyenne de la série (y_i) . Le point G de coordonnées (\bar{x}, \bar{y}) est appelé point moyen du nuage de points associé cette série statistique double. Ainsi

Le point moyen.

Définition.

Soit \bar{x} la moyenne de la série (x_i) et \bar{y} la moyenne de la série (y_i) . Le point G de coordonnées (\bar{x}, \bar{y}) est appelé point moyen du nuage de points associé cette série statistique double. Ainsi

$$G(\bar{x}, \bar{y})$$

avec

Le point moyen.

Définition.

Soit \bar{x} la moyenne de la série (x_i) et \bar{y} la moyenne de la série (y_i) . Le point G de coordonnées (\bar{x}, \bar{y}) est appelé **point moyen** du nuage de points associé cette série statistique double. Ainsi

$$G(\bar{x}, \bar{y})$$

avec

$$\bar{x} = \frac{\sum x_i}{N}$$

Le point moyen.

Définition.

Soit \bar{x} la moyenne de la série (x_i) et \bar{y} la moyenne de la série (y_i) . Le point G de coordonnées (\bar{x}, \bar{y}) est appelé point moyen du nuage de points associé cette série statistique double. Ainsi

$$G(\bar{x}, \bar{y})$$

avec

$$\bar{x} = \frac{\sum x_i}{N} \quad \text{et} \quad \bar{y} = \frac{\sum y_i}{N}$$

Le point moyen.

Définition.

Soit \bar{x} la moyenne de la série (x_i) et \bar{y} la moyenne de la série (y_i) . Le point G de coordonnées (\bar{x}, \bar{y}) est appelé point moyen du nuage de points associé cette série statistique double. Ainsi

$$G(\bar{x}, \bar{y})$$

avec

$$\bar{x} = \frac{\sum x_i}{N} \quad \text{et} \quad \bar{y} = \frac{\sum y_i}{N}$$

Exemple

Déterminer le point moyen de la série B1.

Plan

- 1 Introduction
- 2 Représentation graphique. Nuage de points
- 3 Paramètres d'une série statistique double.
- 4 Les droites de regression.

Définition

Covariance de (x,y) et les variances

On appelle covariance de la série statistique double de variables x et y le nombre réel :

$$\text{cov}(x, y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{N} = \frac{\sum x_i y_i}{N} - \bar{x} \bar{y}$$

Définition

Covariance de (x,y) et les variances

On appelle covariance de la série statistique double de variables x et y le nombre réel :

$$\text{cov}(x, y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{N} = \frac{\sum x_i y_i}{N} - \bar{x}\bar{y}$$

les variances de x et de y sont

$$V(x) = \text{cov}(x, x) \quad \text{et} \quad V(y) = \text{Cov}(y, y)$$

Remarque

La variance d'une variable est positive et le nombre $\sqrt{V(x)} = \sigma_x$ est l'écart-type de x.

Définition

Droites de régressions. Par la méthode des moindres carrés

- La droite de régression D_1 de y en x est l'équation

Définition

Droites de régressions. Par la méthode des moindres carrés

- La droite de régression D_1 de y en x est l'équation $y = ax + b$ avec $a = \frac{\text{cov}(x,y)}{V(x)}$ et $b = \bar{y} - a\bar{x}$.

Définition

Droites de régressions. Par la méthode des moindres carrés

- La droite de régression D_1 de y en x est l'équation $y = ax + b$ avec $a = \frac{\text{cov}(x,y)}{V(x)}$ et $b = \bar{y} - a\bar{x}$.
- La droite de régression D_2 de x en y est l'équation

Définition

Droites de régressions. Par la méthode des moindres carrés

- La droite de régression D_1 de y en x est l'équation $y = ax + b$ avec $a = \frac{\text{cov}(x,y)}{V(x)}$ et $b = \bar{y} - a\bar{x}$.
- La droite de régression D_2 de x en y est l'équation $x = a'x + b'$ avec $a' = \frac{\text{cov}(x,y)}{V(y)}$ et $b' = \bar{x} - a'\bar{y}$.

Définition

Droites de régressions. Par la méthode des moindres carrés

- La droite de régression D_1 de y en x est l'équation $y = ax + b$ avec $a = \frac{\text{cov}(x,y)}{V(x)}$ et $b = \bar{y} - a\bar{x}$.
- La droite de régression D_2 de x en y est l'équation $x = a'x + b'$ avec $a' = \frac{\text{cov}(x,y)}{V(y)}$ et $b' = \bar{x} - a'\bar{y}$.

Remarque

Le point moyen G du nuage appartient toujours aux deux droites de régressions

Définition

Le coefficient de corrélation.

Le coefficient de corrélation linéaire d'une série statistique de variables x et y est le nombre r défini par :

Définition

Le coefficient de corrélation.

Le coefficient de corrélation linéaire d'une série statistique de variables x et y est le nombre r défini par :

$$r = \frac{\text{cov}(x, y)}{\sigma(x) \cdot \sigma(y)}.$$

Coefficient de corrélation.

Interprétation.

- Ce coefficient sert à mesurer la qualité d'un ajustement affine.
- Plus le coefficient de corrélation linéaire est proche de 1 en valeur absolue, meilleur est l'ajustement linéaire.

Coefficient de corrélation.

Interprétation.

- Ce coefficient sert à mesurer la qualité d'un ajustement affine.
- Plus le coefficient de corrélation linéaire est proche de 1 en valeur absolue, meilleur est l'ajustement linéaire.
- Lorsque $r = \pm 1$, la droite de régression passe par tous les points du nuage, qui sont donc alignés.

Coefficient de corrélation.

Interprétation.

- Ce coefficient sert à mesurer la qualité d'un ajustement affine.
- Plus le coefficient de corrélation linéaire est proche de 1 en valeur absolue, meilleur est l'ajustement linéaire.
- Lorsque $r = \pm 1$, la droite de régression passe par tous les points du nuage, qui sont donc alignés.
- Le coefficient de corrélation linéaire r vérifie $-1 \leq r \leq 1$.